Binäre Dateiformate

Bakera

Links, Beispieldateien und eine farbige Version dieses Dokumentes sind unter `go.bakera.de/bindat` verfügbar.

Grob lassen sich Dateien in zwei Formate einteilen: Textdateien und Binärdateien. Ein Binärformat, das sich leicht analysieren und verstehen lässt, ist das Bitmap-Bildformat von Windows. Hierbei handelt es sich um ein Rasterformat, das Bilder Pixel für Pixel aufbaut.

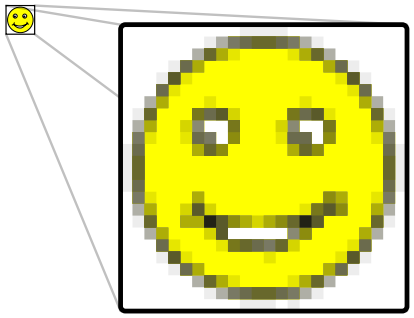

Wie ist ein solches Bild genau aufgebaut? Betrachten wir das Bildformat BMP im Detail und fangen mit dem Testbild auf der rechten Seite an, welches aus 3 x 2 Pixeln besteht Zum Nachvollziehen kannst du es mit Paint nachmalen und als 24 Bit RGB-Bild abspeichern oder bei den Links herunterladen.

Abbildung 1: Ein Bild mit 3 x 2 = 6 Pixeln

Der Quelltext in Abb. 2 zeigt, wie eine Datei byteweise eingelesen werden kann. Zeile 1 öffnet die Datei als Binärdatei im lesenden Modus (»rb«). Zeile 2 liest genau ein Byte aus dem Stream. Der Aufruf von `read` liefert eine Liste aus Bytes zurück, aus denen das erste Byte extrahiert wird. In der Schleife wird jedes Byte bis zum Ende der Datei ausgelesen. Zeile 3 prüft hierbei, ob das Lesen des Bytes erfolgreich war und bricht die Schleifen ab, falls nicht. Zeile 6 schließt die Datei wieder.

```
1  f = open('3x2.bmp', 'rb')
2  einByte = f.read(1)[0]
3  while einByte:
4      # Das Byte verarbeiten
5      einByte = f.read(1)[0]
6  f.close()
```

Abbildung 2: Eine Datei in Python byteweise lesen

Eine alternative Methode für den Dateizugriff und weitere Details stehen in der offiziellen Python-Dokumentation, die bei den Materialien verlinkt ist.

Auftrag 1 (Hexdump) *Erstelle ein Programm, das eine BMP-Datei einliest und den Inhalt als Hexadezimalwert auf der Konsole ausgibt. Es sollte eine Ausgabe ähnlich der unten abgedruckten produzieren.*

Wir betrachten das Bild aus Abb. 1 nun byteweise und schauen uns die markierten Stellen genauer an. Rechts sind die Werte zusammengefasst dargestellt.

```
42 4d 4e 00 00 00 00 00   00 00 36 00 00 00 28 00
00 00 03 00 00 00 02 00   00 00 01 00 18 00 00 00
00 00 18 00 00 00 c4 0e   00 00 c4 0e 00 00 00 00
00 00 00 00 00 00 24 1c   ed ff ff ff 00 00 00 00
00 00 ff ff ff 7f 7f 7f   ff ff ff 00 00 00
```

Hexwert	Bedeutung
42 4d	„BM“
4e	Dateigröße: 78 Bytes
36	Start der Bilddaten (Offset)
03	Auflösung (Breite)
02	Auflösung (Höhe)

Die ersten Bytes einer Binärdatei werden als »magic number« (»magische Zahl«) bezeichnet, da man anhand dieser Zahlen häufig

auf das Dateiformat schließen kann. Abbildung 3 zeigt Beispiele bekannter Dateiformate und ihrer »magic number«.

Die ersten beiden Bytes mit dem Inhalt $0x42$ und $0x4d$ sind die *magic number* des Bitmap-Dateiformates und stehen für die Buchstaben »BM«, wenn man sie als ASCII-Wert interpretiert – also Bitmap. Durch das voran gestellte „$0x$“ wird kenntlich gemacht, dass der Hexwert 42 gemeint ist und nicht die dezimale Zahl 42. Es folgt ein Byte ($0x4e$), welches die Größe (hier dezimal 78) in Bytes angibt. Eigentlich beschreiben 4 Bytes die Dateigröße, nämlich die Stellen `4e 00 00 00`. Bei dem zehnten Byte (an Position $0x0a$) steht eine $0x36$, die den Offset bis zum Beginn der Bilddaten angibt.

Ab dem Byte $0x36$ folgen die Bilddaten. Hierbei sind pro Pixel drei Byte abgelegt – für jede Farbe Rot, Grün und Blau jeweils ein Byte. Die Daten sind im *Little-Endian-Format* kodiert. Daher werden die Werte nicht als RGB-, sondern als BGR-Werte gespeichert.

Hex	ASCII	Dateityp
424d	BM	BMP
cafebabe	–	Java Classfile
4d5a	MZ	EXE
5a4d	ZM	

Abbildung 3: Interessante „magic numbers“

Rot (drei Bytes)	Endianess
`00 00 ff`	little
`ff 00 00`	big

Big-Endian beschreibt die gewöhnliche Reihenfolge, bei der die höherwertigen Stellen links stehen.

Bei *Little-Endian* werden zuerst die niederwertigen und anschließend die höherwertigen Bytes dargestellt – also »falsch herum«.

Ein weiteres Beispiel fasst die Zusammenhänge noch einmal für ein anderes Bild zusammen. Diesmal mit einer Auflösung von 4 x 2 Pixeln.[1]

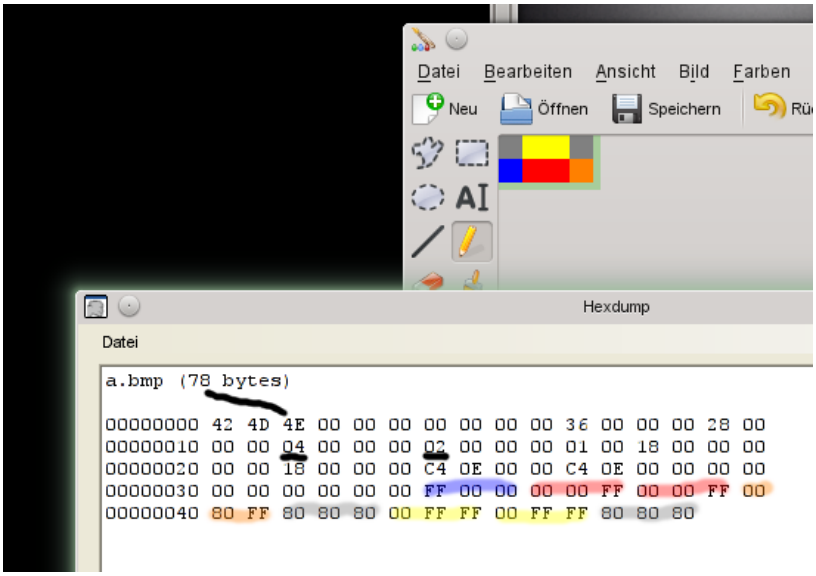

[1] Die Zeile hat nun vier Pixel, da die Bildzeilen im Bitmap-Format immer mit Nullen aufgefüllt werden, bis sie ein Vielfaches von vier ergeben. So werden in diesem Beispiel »sinnlose« Informationen im Bild vermieden.

In dem Hexdump sind Stellen, die Farbinformationen enthalten, farblich hervorgehoben.[2] Man erkennt, wie die Zeilen von unten nach oben und von links nach rechts aufgebaut werden.

Im dritten Byte finden wir wieder die Dateigröße – in diesem Fall den Wert $0x4E$, was wieder einer dezimalen 78 entspricht.

Die Auflösung finden wir in den Bytes an den Positionen $0x12$ (der Wert $0x4$) und $0x16$ (der Wert $0x2$). Dieser Wert wird wieder in *little-endian* in 4 Bytes abgespeichert.

[2] In einem Ausdruck in schwarz-weiß sind die Farben nicht zu erkennen. Bei den Materialien befindet sich eine farbige Version dieses Dokuments.

Auftrag 2 (BMP Info) *Erstelle ein Programm, welches eine BMP-Datei als Eingabe erhält und auf der Konsole die Metadaten der Datei und Farbinformationen für rot, grün und blau ausgibt. Eine mögliche Beispielausgabe ist rechts abgebildet.*

```
Dateigröße: 78 Bytes
Auflösung: 2 x 3 Pixel
Pixel 0 RGB: 0 0 0
Pixel 1 RGB: 127 127 127
Pixel 2 RGB: 255 255 255
...
```

Abbildung 4: Informationen zu einer BMP-Datei.

Auftrag 3 (RGB-Splitter) *Erstelle ein Programm, das eine BMP-Datei als Eingabe erhält und daraus drei Dateien erzeugt: eine Datei für jede Farbinformation rot, grün und blau – vgl. Abb. 5*

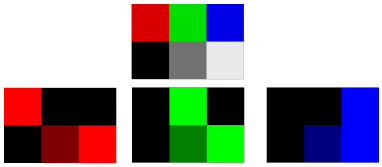

Abbildung 5: Oben das Original, unten die einzelnen Farbkanäle rot, grün und blau.

Übersicht Die folgende Abbildung fasst die unterschiedlichen Informationen zusammen. Zuerst wird das Dateiformat mit »BM« gekennzeichnet. Es folgen die Dateigröße und ein Hinweis auf die Stelle, ab der die Bilddaten beginnen. Dann folgen Informationen zur Auflösung und Details über den Aufbau der Bilddaten. Schließlich werden die Pixeldaten gelistet und bei Bedarf mit Nullen aufgefüllt. Viele dieser Informationen sind in *little endian* über 4 Bytes gespeichert.

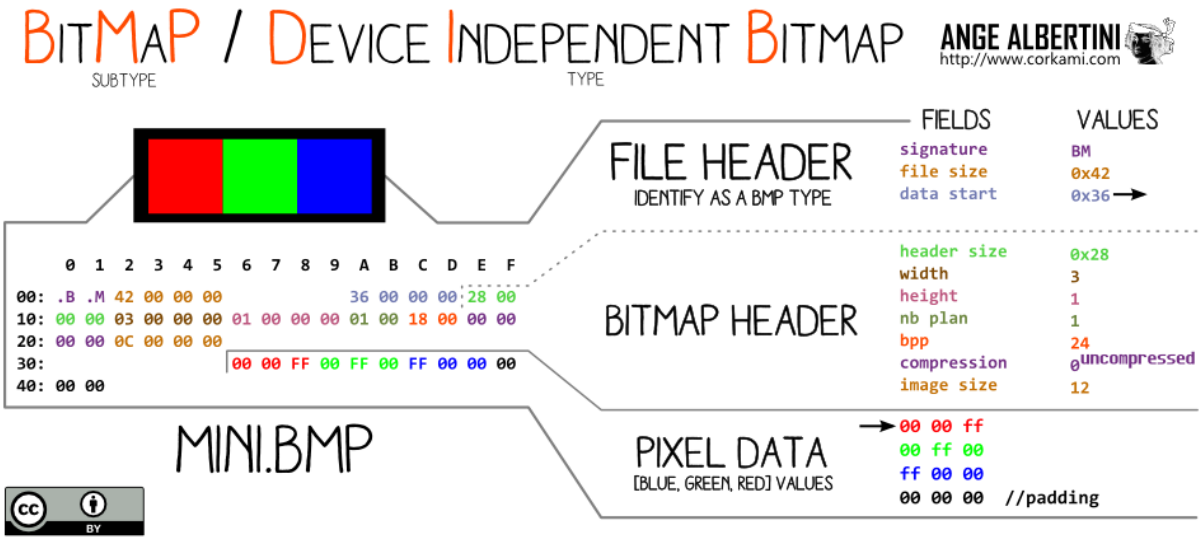

Anwendung: Steganographie Es wäre nun leicht, die Bildinformationen einzelner Pixel zu ändern, um geheime Botschaften in der Bilddatei zu verstecken – wie in einem Steganogramm.[3] Hierzu wird z.B. bei jedem Farbwert das letzte Bit auf eine 0 oder 1 gesetzt, um eine Botschaft binär in den Bilddaten zu verstecken. Da der Farbwert nur um maximal eins verändert wird, fällt dies bei Betrachtung eines Bildes nicht auf.

[3] Der Wikipedia-Artikel »Computergestützte Steganographie« (in den Materialien verlinkt) beschreibt das Vorgehen genauer.

Auftrag 4 (Steganographie) *Bei den Materialien befindet sich eine Datei, die eine Geheimbotschaft enthält. Versuche Sie auszulesen.*

Schreibe ein Programm, das eine Geheimbotschaft in den Bilddaten einer Bitmap-Datei versteckt.